第三章用R软件作数据的描述性分析

本节主要内容

- 3.1 描述性统计量

1 描述性统计量

已知一组试验（或观测）数据为

$$x_1, x_2, \cdots, x_n$$

它们可以是从所要研究的对象的全体—X中取出的，这n个观测值就构成一个样本。在某些简单的实际问题中，这n个观测值就是所要研究问题的全体。数据分析的任务就是要对这全部n个数据进行分析，提取数据中包含的有用信息。

数据作为信息载体，当然要分析数据中包含的主要信息，即要分析数据的主要特征。也就是说，要研究数据的数字特征。对于数据的数字特征，要分析数据的集中位置、分散程度和数据分布等。

3.1.1 位置的度量

所谓位置的度量就是那些用来描述定量资料的集中趋势的统计量。 常用的有均值、众数、中位数、百分位数等。

1 均值

均值(**mean**)是数据的平均数， 均值(记为 $\overline{x}$)定义为

$$\overline{x} = \frac{1}{n}\sum_{i=1}^{n} x_i, \qquad (3.1)$$

它描述数据取值的平均位置。

在**R**软件中, 可用**mean()**函数计算样本的均值，其的使用方法是

mean(x, trim = 0, na.rm = FALSE)

其中**x**是对象(如向量、矩阵、数组或数据框)，**trim**是计算均值前去掉与均值差较大数据的比例，缺省值为**0**，即包括全部数据。

当na.rm = TRUE时，允许数据中有缺失数据。函数的返回值是对象的均值。有关它的使用，将用例子来作进一步的介绍。

例3.1 已知**15**位学生的体重(单位：千克)

75.0 64.0 47.4 66.9 62.2 62.2 58.7 63.5

66.6 64.0 57.0 69.0 56.9 50.0 72.0

求学生体重的平均值。

解 利用**mean()**函数求解。建立**R**文件(文件名**exam11.R**)

```
w <- c(75.0, 64.0, 47.4, 66.9, 62.2, 62.2,
58.7, 63.5, 66.6, 64.0, 57.0, 69.0,
56.9, 50.0, 72.0)
w.mean <- mean(w); w.mean
```

执行**exam11.R**的的全部程序得到学生体重的均值为**62.36**。

但如果在数据中，某些数据是异常值，就不能直接用**mean()**。例如，如果第一个学生的体重少输入一个点，变为**750**千克，此时有

```
> w[1] <- 750 # 改变向量w第一个分量的值.
> w.mean <- mean(w); w.mean
[1] 107.36
```

学生的平均体重为**107.36**千克，显然是不合理的。

如果选用参数**trim**就会减少由于输入误差对计算的影响，如

```
> w.mean <- mean(w, trim = 0.1); w.mean
[1] 62.53846
```

其中**trim**的取值在**0**至**0.5**之间， 表示在计算均值前需要去掉异常值的

比例。 这里选择**trim = 0.1**， 即表明去掉**10%**的异常值。 也就是说，在计算中不会用到输入有错的数据**750**， 得到的计算结果趋于合理。因此，利用参数**trim**可以有效的改善异常值的对计算的影响。

2. 顺序统计量

设n个数据(观测值)按从小到大的顺序排列为

$$x_{(1)} \le x_{(2)} \le \cdots \le x_{(n)},$$

称为顺序统计量(order statistic)，显然, 最小顺序统计量为 $x_{(1)}$ 最大顺序统计量为 $x_{(n)}$

在R软件中， sort()给观测量的顺序统计量，如

```
> x <- c(75, 64, 47.4, 66.9, 62.2, 62.2, 58.7, 63.5)
> sort(x)
[1] 47.4 58.7 62.2 62.2 63.5 64.0 66.9 75.0
```

实际上，函数sort()不单单给出了样本的顺序统计量，还有更广泛的功能， 其使用格式为

```
sort (x, partial = NULL, na.last = NA,
      decreasing = FALSE,
      method = c("shell", "quick"),
```

index.return = FALSE)

其中**x**是数值、或字符、或逻辑型向量. **decreasing**是逻辑变量, 控制数据排列的顺序, 当**decreasing = FALSE** (缺省值), 给出的返回值, 是由小到大排序的; 如果**decreasing = TRUE**, 则函数的返回值由大到小排列. **index.return** 是逻辑变量, 是控制排序下标的返回值, 当**index.return = TRUE**时(缺省值为**FALSE**), 函数的返回值是一列表, 列表的第一个变量**$x**是排序的顺序, 第二个变量是**$ix**是排序顺序的下标对应的值.

如

```
> sort(x, decreasing = TRUE)
 [1] 75.0 66.9 64.0 63.5 62.2 62.2 58.7 47.4
> sort(x, index.return = TRUE)
 $x
[1] 47.4 58.7 62.2 62.2 63.5 64.0 66.9 75.0
 $ix
 [1] 3 7 5 6 8 2 4 1
```

3. 中位数

中位数(**median**, 记为m_e)定义为数据排序位于中间位置的值, 即

$$m_e = \begin{cases} x_{(\frac{n+1}{2})}, & \text{当}n\text{为奇数时} \\ \frac{1}{2}(x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)}), & \text{当}n\text{为偶数时} \end{cases}$$

中位数描述数据中心位置的数字特征. 大体上比中位数大或小的数据个数为整个数据的一半. 对于对称分布的数据, 均值与中位数比较接近; 对于偏态分布的数据, 均值与中位数不同. 中位数的又一显著特点是不受异常值的影响, 具有稳健性, 因此它是数据分析中相当重要的统计量.

在**R**软件中, 函数**median()**给观测量的中位数. 如

```
> x <- c(75, 64, 47.4, 66.9, 62.2, 62.2,
         58.7, 63.5)
```

```
> median(x)
 [1] 62.85
```

median()函数的使用格式为

```
median(x, na.rm = FALSE)
```

其中**x**是数值型向量.

4. 百分位数

百分位数**(percentile)**是中位数的推广. 将数据按从小到大的排列后, 对于 $0 \le p < 1$,它的**p**分位点定义为

$$m_p = \begin{cases} x_{([np]+1)}, & \text{当} np \text{不是整数时} \\ \frac{1}{2}(x_{(np)} + x_{(np+1)}), & \text{当} np \text{是整数时} \end{cases}$$

其中**[np]**表示**np**的整数部分.

p分位数又称为第**100p**百分位数. 大体上整个样本的**100p**的观测值不超过**p**分位数. 如**0.5**分位数$m_{0.5}$**(**第**50**百分位数**)**就是中位数 m_e. 在实际

计算中, 0.75分位数与0.25分位数(第75百分位数与第25百分位数)比较重要, 它们分别称为上、下四分位数, 并分别记为Q3 = m0.75, Q1 = m0.25.

在R软件中, quantile()函数计算观测量的百分位数. 如

```
> w <- c(75.0, 64.0, 47.4, 66.9, 62.2, 62.2,
         58.7, 63.5, 66.6, 64.0, 57.0, 69.0,
         56.9, 50.0, 72.0)
> quantile(w)
     0%     25%   50%   75%  100%
  47.40   57.85 63.50 66.75 75.00
```

quantile()函数的一般使用格式为

```
quantile(x, probs = seq(0, 1, 0.25),
na.rm = FALSE,
names = TRUE, type = 7, ...)
```

其中x是由数值构成的向量. probs是给出相应的百分位数, 缺省时

是0、1/4、1/2、3/4、1. na.rm 是逻辑变量, 当na.rm = TRUE时, 可处理缺失数据. 其余见帮助.

如果打算给出0%, 20%, 40%, 60%, 80%和100%的百分位数, 则选择

```
> quantile(w, probs = seq(0, 1, 0.2))
     0%   20%   40%  60%   80% 100%
47.40 56.98 62.20 64.00 67.32 75.00
```

其中seq(0, 1, 0.2)表示生成一个从0开始到1结束且间隔为0.2的向量.

1.2 分散程度的度量

表示数据分散或变异程度的特征量有方差、标准差、极差、四分位极差、变异系数和标准误等.

1. 方差、标准差与变异系数

方差(**variance**)是描述数据取值分散性的一个度量. 样本方差(**sample variance**)是样本相对于均值的偏差平方和的平均,记为 s^2, 即

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2$$

其中, $\bar{x}$ 是样本的均值，即式(**1.1**)的计算值。

样本方差的开方称为样本标准差(**standard deviation**), 记为**s**, 即

$$s = \sqrt{s^2} = \sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2}.$$

变异系数是刻划数据相对分散性的一种度量, 记为**CV**,

$$CV = 100 \times \frac{s}{\bar{x}}(\%),$$

它是一个无量纲的量, 用百分数表示.

与分散程度有关的统计量还有下列数字特征:

样本校正平方和

$$CSS = \sum_{i=1}^{n} (x_i - \bar{x})^2.$$

样本未校正平方和

$$USS = \sum_{i=1}^{n} x_i^2.$$

在**R**软件中, 若**x**是由样本构成的向量, 则**var(x)**计算样本方差, **sd(x)** 计算样本标准差, 即$sd(x) = \sqrt{\mathrm{var}(x)}$. 例如, 对于**15**名学生的体重数据, 有

```
> var(w)
 [1] 56.47257
> sd(w)
 [1] 7.514823
```

方差函数**var()**和标准差函数**sd()**的使用格式为

var(x, y = NULL, na.rm = FALSE, use)

sd(x, na.rm = FALSE)

其中**x**是数值向量、矩阵或数据框.

与方差函数**var()**相关的函数还有: **cov()**—求协方差矩阵; **cor()**—求相关矩阵.

对于变异系数、校正平方和、未校正平方和等指标, 需要编写简单的程序. 例如, 对于**15** 名学生的体重数据

```
> cv <- 100*sd(w)/mean(w); cv
 [1] 12.05071
> css <- sum((w-mean(w))^2); css
 [1] 790.616
> uss <- sum(w^2); uss
 [1] 59122.16
```

2. 极差与标准误

样本极差(记为**R**)的计算公式为

$$R = x_{(n)} - x_{(1)} = \max(x) - \min(x),$$

其中**x**是由样本构成的向量. 样本极差是描述样本分散性的数字特征. 当数据越分散, 其极差越大.

样本上、下四分位数之差称为四分位差（或半极差）, 记为**R1**, 即

$$R_1 = Q_3 - Q_1,$$

它也是度量样本分散性的重要数字特征, 特别对于具有异常值的数据, 它作为分散性具有稳健性, 因此它在稳健性数据分析中具有重要作用.

样本标准误(记为s_m)定义为

$$s_m = \sqrt{\frac{1}{n(n-1)}\sum_{i=1}^{n}(x_i - \bar{x})^2} = \frac{s}{\sqrt{n}}.$$

对于样本极差与样本标准误, 可以简单编程方法计算.

1.3 分布形状的度量

1. 偏度系数

设总体X的中心矩 $\mu_2 = E(X - E(X))^2, \mu_3 = E(X - E(X))^3$ 存在，则称

$$C_s = \mu_3 / \mu_2^{\frac{3}{2}}$$

为总体X的偏度系数(coefficient of skewness).

样本的偏度系数(记为**g1**)的计算公式为

$$g_1 = \frac{n}{(n-1)(n-2)s^3}\sum_{i=1}^{n}(x_i - \bar{x})^3 = \frac{n^2 \hat{\mu}_3}{(n-1)(n-2)s^3},$$

其中**s**是样本标准差, $\hat{\mu}_3$ 是样本**3**阶中心矩,即 $\hat{\mu}_3 = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^3.$

偏度系数是刻划数据的对称性指标. 关于均值对称的数据其偏度系数为**0**, 右侧更分散的数据偏度系数为正, 左侧更分散的数据偏度系数为
负. 图**1**给出了数据直方图与偏度的关系, 有关直方图的概念将在下面介绍.

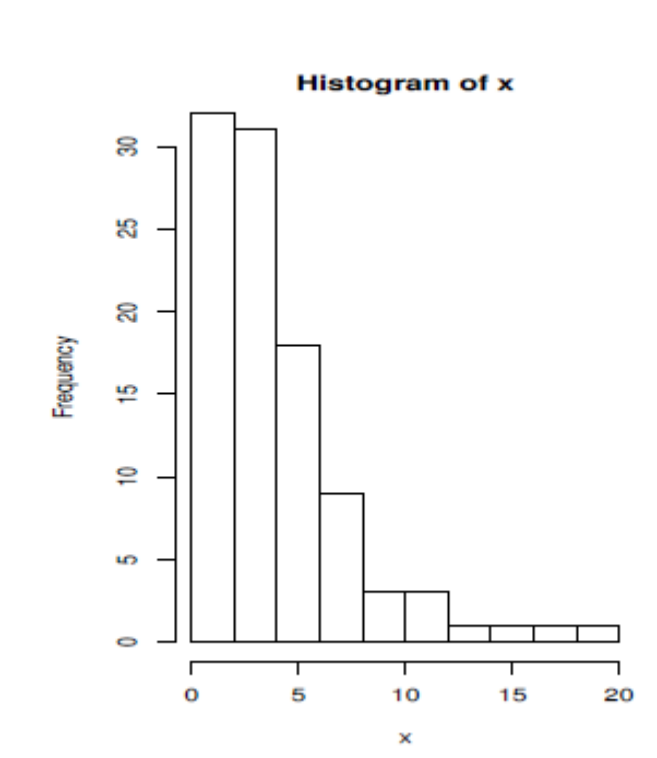

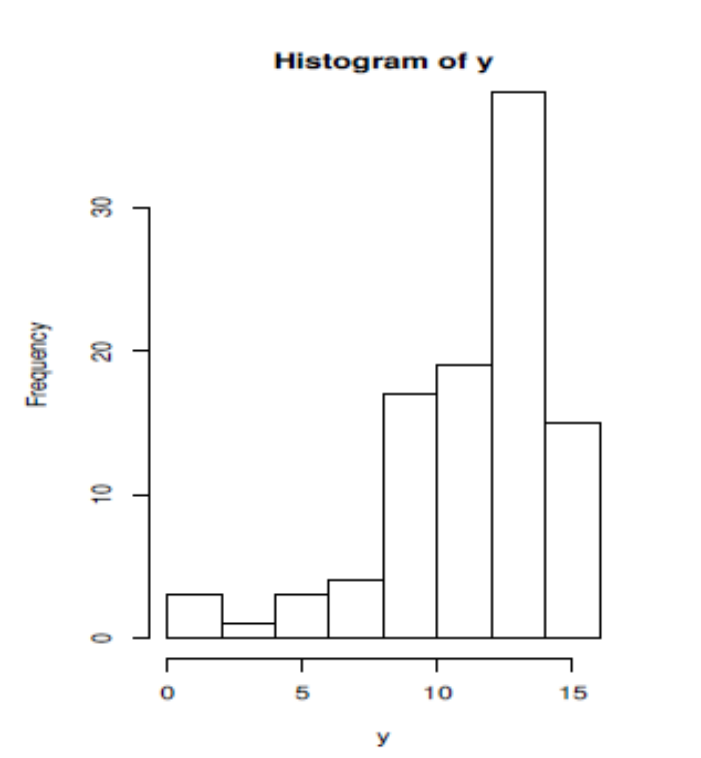

图**1:** 数据的直方图与与偏度的关系**,** 数据**X**的偏度为正**,** 数据**Y** 的偏度为负

2. 峰度系数

设总体**X**的中心矩 $\mu_2 = E(X - E(X))^2, \mu_4 = E(X - E(X))^4$ 存在，则称

$$-3C_k = \mu_4 / \mu_2^2$$

为总体**X**的峰度系数**(coefficient of kurtosis).**
样本的峰度系数**(**记为**g2)**的计算公式为

$$g_2 = \frac{n(n+1)}{(n-1)(n-2)(n-3)s^4}\sum_{i=1}^{n}(x_i - \bar{x})^4 - 3\frac{(n-1)^2}{(n-2)(n-3)}$$

$$= \frac{n^2(n+1)\hat{\mu}_4}{(n-1)(n-2)(n-3)s^4} - 3\frac{(n-1)^2}{(n-2)(n-3)},$$

其中，**s**是样本标准差**,** $\hat{\mu}_4$是样本**4**阶中心矩**,** 即 $\hat{\mu}_4 = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^4$.
当数据的总体分布为正态分布时**,** 峰度系数近似为**0;** 当分布较正态分
布的尾部更分散时**,** 峰度系数为正**;** 否则为负**.** 当峰度系数为正时**,** 两

侧极端数据较多; 当峰度系数为负时, 两侧极端数据较少.

最后编写一个统计的函数(程序名**data_outline.R**), 计算样本的各种描述性统计量.

```
data_outline <- function(x){
  n <- length(x)
  m <- mean(x)
  v <- var(x)
  s <- sd(x)
  me <- median(x)
  cv <- 100*s/m
  css <- sum((x-m)^2)
  uss <- sum(x^2)
  R <- max(x)-min(x)
  R1 <- quantile(x,3/4)-quantile(x,1/4)
  sm <- s/sqrt(n)
  g1 <- n/((n-1)*(n-2))*sum((x-m)^3)/s^3
```

```
g2 <- ((n*(n+1))/((n-1)*(n-2)*(n-3))
        *sum((x-m)^4)/s^4
        - (3*(n-1)^2)/((n-2)*(n-3)))
data.frame(N=n, Mean=m, Var=v, std_dev=s,
     Median=me, std_mean=sm, CV=cv,
     CSS=css, USS=uss, R=R, R1=R1,
     Skewness=g1, Kurtosis=g2, row.names=1)
}
```

函数的输入变量**x**是数值型向量, 由样本构成. 函数的返回值是数据框, 包含以下指标: **N**样本的个数; **Mean**样本均值; **Var**样本方差; **std_dev** 样本标准差; **Median**样本中位数; **std_mean**样本的标准误; **CV**样本的变异系数; **CSS**样本校正平方和; **USS**样本未校正平方和; **R**样本极差; **R1**样本半极差; **Skewness**样本峰度系数; **Kurtosis**样本偏度系数.

例3.2 计算例**3.1**中**15**位学生的体重的各种统计量.

解　将编好的程序调入内存, 输入数据并计算得到相应的结果.

```
> source("data_outline.R")
> w <- c(75.0, 64.0, 47.4, 66.9, 62.2, 62.2, 58.7, 63.5,
         66.6, 64.0, 57.0, 69.0, 56.9, 50.0, 72.0)
> data_outline(w)
   N   Mean        Var     std_dev  Median  std_mean        CV
1 15  62.36  56.47257  7.514823    63.5   1.940319  12.05071
     CSS        USS      R      R1     Skewness     Kurtosis
1 790.616  59122.16  27.6     8.9   -0.4299561  0.09653947
```